

Création de la base de données

Nous partons de 2 fichiers CSV, Contrat.csv et Region.csv. Partant de ces deux sources, un dictionnaire des données a été créé et rempli.

	Nom des colonnes	Type de données	Taille	Clé	Description
CONTRAT.CSV	Contrat_ID	INT		Clé primaire	Id unique pour les contrats
	No_voie	INT			Numéro dans la voie pour l'adresse du logement assuré
	B_T_Q	CHAR	1		Indicateur éventuel de répétition pour l'adresse du logement assuré sur un caractère
	Type_de_voie	VARCHAR	4		Type de voie pour l'adresse du logement assuré: rue, av (Avenue), rte (Route), ...
	Voie	VARCHAR	26		Libellé de la voie pour l'adresse du logement assuré
	Code_dep_code_commune	VARCHAR	6	Clé secondaire	Concaténation du code département et code commune pour avoir une clé unique
	Code_postal	INT			Code postal pour l'adresse du logement assuré
	Surface	INT			Surface du bien
	Type_local	VARCHAR	11		Type de bien
	Occupation	VARCHAR	12		Type d'occupation
	Type_contrat	VARCHAR	20		Classification résidence
	Formule	VARCHAR	9		Type de formule
	Valeur_declaree_biens	VARCHAR	12		Fourchette de valeur du bien
REGION.CSV	Prix_cotisation_mensuel	INT			Prix de la cotisation mensuelle
	Code_dep_code_commune	VARCHAR	6	Clé primaire	Concaténation du code département et code commune pour avoir une clé unique
	reg_code	VARCHAR	2		Code de la région de la commune
	reg_nom	VARCHAR	26		Nom de la région de la commune
	aca_nom	VARCHAR	24		Nom de l'académie à laquelle est rattachée la commune
	dep_nom	VARCHAR	43		Nom du département de la commune
	com_nom_maj_court	VARCHAR	32		Nom de la commune
	dep_code	VARCHAR	3		Code du département de la commune
	dep_nom_num	VARCHAR	49		Nom + Code du département de la commune

Concernant les types de données :

si une colonne ne contient que des chiffres, sans zéro en première position (sauf si c'est la valeur de la cellule), alors cette colonne est considérée ne contenant que des nombres, type INT.

si une colonne contient au moins une lettre, alors cette colonne est considérée contenant des caractères, VARCHAR.

Ensuite, la question de la taille limite : INT est sur 4 octets, donc rien à spécifier de ce côté-là, mais pas VARCHAR.

Avant de manipuler les données, une copie en a été faite pour être sûr de ne pas accidentellement contaminé les données, et c'est sur cette copie que les manipulations suivantes ont été effectuées : les CSVs ont été transformés sous Excel, et une fonction LEN a été appliquée à toutes les colonnes ayant été spécifiées VARCHAR, puis une fonction MAX pour déterminer la longueur maximale du contenu de chaque colonne.

Des anomalies ont été remarquées dans la colonne Code_dep_code_commune du CSV Contrat:


cette colonne contient entre 1 et 3 chiffres pour le numéro du département plus 3 pour la

commune, les départements français vont de 1 à 95 puis 971 à 976. Les codes commençant par 97 devraient tous avoir un troisième chiffre de département + 3 chiffres de commune, donc 6 chiffres. Il est donc impossible d'avoir des codes à 5 chiffres commençant par 97.

Le site dont est extrait le dataset Region a été consulté pour essayer de corriger les potentielles erreurs de saisie. En l'absence de conclusion satisfaisante, ont été supprimées du CSV Contrat les lignes contenant les Contrat ID 128054, 128056, 128059, 128061, 128064, 128068, 128070, 128077 et 128082 ayant les codes erronés 97460, 97434, 97470, 97460 et 97434.

Une liste des colonnes contenant des cellules vides a été faite pour savoir auxquelles pourrait être appliqué une contrainte « NOT NULL » ou non.

Le schéma relationnel, fait sous SQL Power Architect, reprend exactement le dictionnaire des données. La relation existante entre les deux tables a été supprimée puis recréée, pour s'assurer d'une configuration correcte. Une capture d'écran de ce schéma a été effectuée, puis un export du code SQL servant à créer ce schéma a été fait via l'outil Forward SQL de Power Architect.



PostgreSQL étant déjà installé sur la machine, c'est ce SGBD qui a été utilisé. Une nouvelle base de données a été créée, et les tables créées avec le code exporté précédemment. Ces tables ont ensuite été remplies via l'outil d'import de données de PostgreSQL.

```

CREATE TABLE Region (
    Code_dep_code_commune VARCHAR(6) NOT NULL,
    reg_code INTEGER NOT NULL,
    reg_nom VARCHAR(26) NOT NULL,
    aca_nom VARCHAR(24) NOT NULL,
    dep_nom VARCHAR(43) NOT NULL,
    com_nom_maj_court VARCHAR(32) NOT NULL,
    dep_code VARCHAR(3) NOT NULL,
    dep_nom_num VARCHAR(49) NOT NULL,
    CONSTRAINT Region_pk PRIMARY KEY (Code_dep_code_commune)
);

CREATE TABLE Contrat (
    Contrat_ID INTEGER NOT NULL,
    No_voie INTEGER,
    B_T_Q CHAR(1),
    Type_de_voie VARCHAR(4),
    Voie VARCHAR(26) NOT NULL,
    Code_dep_code_commune VARCHAR(6) NOT NULL,
    Code_postal INTEGER NOT NULL,
    Surface INTEGER NOT NULL,
    Type_local VARCHAR(11) NOT NULL,
    Occupation VARCHAR(12) NOT NULL,
    Type_contrat VARCHAR(20) NOT NULL,
    Formule VARCHAR(9) NOT NULL,
    Valeur_declaree_biens VARCHAR(12) NOT NULL,
    Prix_cotisation_mensuel INTEGER NOT NULL,
    CONSTRAINT Contrat_pk PRIMARY KEY (Contrat_ID)
);

ALTER TABLE Contrat ADD CONSTRAINT Region_Contrat_fk
FOREIGN KEY (Code_dep_code_commune)
REFERENCES Region (Code_dep_code_commune)
ON DELETE NO ACTION
ON UPDATE NO ACTION
NOT DEFERRABLE

```